

Tối Ưu Danh Mục Đầu Tư Chứng Khoán

Team CortexIQ

2025

Tóm tắt nội dung

Phân tích danh mục đầu tư là một trong những vấn đề quan trọng được các nhà đầu tư đặc biệt quan tâm. Việc phân tích dữ liệu và xây dựng danh mục đầu tư tối ưu hiệu quả dựa trên các chỉ số tài chính và xu hướng thị trường giúp đưa ra quyết định thông minh hiệu quả hơn. Báo cáo kỹ thuật này nhằm trình bày quá trình tinh chỉnh các mô hình học sâu nhằm dự báo giá cổ phiếu và tối ưu hóa danh mục đầu tư. Quy trình bao gồm tiền xử lý dữ liệu, kỹ thuật tạo đặc trưng, lựa chọn đặc trưng và huấn luyện mô hình cho việc tối ưu hóa danh mục. Thông qua các chỉ số như MAPE, RMSE, Sharpe Ratio và tăng trưởng danh mục đầu tư, báo cáo đề xuất các chiến lược điều chỉnh và quản lý rủi ro để cải thiện hiệu quả dự báo và đầu tư.

1 Giới thiệu


Dự đoán xu hướng giá cổ phiếu trung hạn có tiềm năng ứng dụng cho các nhà đầu tư mà không cần hạ tầng giao dịch tần số cao. Khác với dự đoán chỉ số thị trường, giá cổ phiếu riêng lẻ thường chịu ảnh hưởng lớn từ nhiễu (noise) và xu hướng dài hạn vốn tự động hội tụ về hiệu suất thị trường của công ty. Chính vì thế, chúng tôi tập trung việc dự đoán cổ phiếu trung hạn (30-90 ngày) và việc dự đoán mỗi giá cổ phiếu sẽ được tối ưu hóa thêm bằng các nguồn thông tin bên ngoài như của VN30, VNINDEX đồng thời thông tin từ báo cáo tài chính, dòng tiền và các chỉ số, tỷ số tài chính. Mặc dù giả thuyết thị trường hiệu quả cho rằng biến động giá cổ phiếu tuân theo mô hình đi bộ ngẫu nhiên và do đó bản chất không thể dự đoán chính xác, thí nghiệm cho thấy rằng với 2021 ngày giao dịch làm tập huấn luyện, chúng tôi có thể dự đoán giá đóng cửa của hơn 20 mã cổ phiếu từ các mảng khác nhau như công nghệ, bất động sản,... với độ chênh lệch tương đối nhỏ.

Với giá cổ phiếu ngày càng chính xác, chúng tôi có thể đưa ra những lời khuyên cho việc đầu tư nhằm tối ưu hóa lợi nhuận và giảm thiểu rủi ro.

Từ khóa: dự đoán cổ phiếu, lựa chọn đặc trưng, kỹ thuật tạo đặc trưng, LSTM, GRU, chỉ số tài chính


2 Chu Trình

Dưới đây là pipeline hoàn chỉnh của bài toán tối ưu hóa danh mục đầu tư. Phần đầu tiên là phần xử lý dữ liệu. Chúng tôi cố gắng tối đa hoá việc cung cấp càng nhiều thông tin cho mỗi mã cổ phiếu. Để làm được điều này chúng tôi tận dụng VNSTOCK3 API để cào dữ liệu, cộng thêm với việc tạo ra các đặc trưng liên quan đến chỉ số tài chính dựa trên thông tin thô sơ ban đầu.




Hình 1: Quy trình xử lý dữ liệu

Tiếp theo là giai đoạn tối ưu hoá mô hình. Chúng tôi chia làm hai bước. Bước đầu, chúng tôi sử dụng ba loại mô hình học sâu phổ biến cho bài toán chuỗi thời gian để đưa ra dự đoán giá đóng cửa của từng cổ phiếu.



Hình 2: Dự đoán giá cổ phiếu bằng mô hình học sâu

Ở giai đoạn hai, chúng tôi sử dụng các giá cổ phiếu dự đoán để tính toán lợi suất trung bình cho từng mã cổ phiếu dựa trên các mốc thời gian 30, 60, 90 và 180 ngày. Vector lợi suất trung bình sau đó được đưa vào mô hình Portfolio Optimizer để tối ưu phân bổ trọng số danh mục đầu tư, đồng thời tính toán giá trị danh mục cuối kỳ cùng các chỉ số độ biến động và tỷ lệ Sharpe tương ứng.



Hình 3: Tối ưu hóa danh mục đầu tư dựa trên giá dự đoán

3 Không Gian Đặc Trưng

3.1 Thu thập dữ liệu

Toàn bộ dữ liệu được thu thập từ VNSTOCK3 API. Chúng tôi chọn 20 mã cổ phiếu, trong đó:

- Công nghệ: ITD, POT, FPT, CMG

- **Bất động sản và xây dựng:** VIC, PDR, NLG, KDH
- **Năng lượng:** PVB, PVC, PVD, PVS
- **Ngân hàng và tài chính:** VCB, NVB, CTS, CTG
- **Hàng tiêu dùng:** VNM, MWG, MSN, HAG

Ngoài ra, chúng tôi sử dụng thêm dữ liệu của chỉ số **VN30** — đại diện cho 30 công ty có giá trị vốn hóa và thanh khoản hàng đầu trên sàn HOSE, cũng như chỉ số **VNINDEX** — phản ánh sự biến động giá của toàn bộ cổ phiếu niêm yết trên sàn này. Bên cạnh chuỗi thời gian giá, mỗi mã cổ phiếu còn được bổ sung thông tin từ **dòng tiền**, **báo cáo tài chính**, và **các tỷ số tài chính** nhằm tăng cường mức độ biểu đạt của đặc trưng đầu vào.

Khoảng thời gian phân tích được lựa chọn kéo dài từ **01/01/2018 đến 31/01/2025**, đảm bảo bao phủ nhiều chu kỳ thị trường và tạo điều kiện thuận lợi cho việc huấn luyện các mô hình học máy.

Nhằm tăng thêm số lượng điểm dữ liệu huấn luyện cũng như hỗ trợ hiệu quả cho quá trình tối ưu hóa mô hình trong các giai đoạn tiếp theo, chúng tôi áp dụng kỹ thuật **nội suy tuyến tính (Linear Interpolation)** để lấp đầy các giá trị bị thiếu trong chuỗi thời gian tài chính có tần suất thấp (theo quý), qua đó đồng bộ hóa chúng với khung thời gian theo ngày của dữ liệu kỹ thuật.

3.2 Chỉ số kỹ thuật

Một chỉ báo kỹ thuật là tập hợp các điểm dữ liệu được tính toán bằng cách áp dụng một hàm lên chuỗi giá tại thời điểm t trong khoảng thời gian nghiên cứu n . Dưới đây là bảng các chỉ báo mà chúng tôi tính toán từ chuỗi thời gian và sử dụng làm đặc trưng đầu vào mô hình.

Chỉ số	Tên tiếng Việt	Mô tả	Công thức
open	Giá mở cửa	Giá tại thời điểm bắt đầu phiên giao dịch	-
close	Giá đóng cửa	Giá tại thời điểm kết thúc phiên giao dịch	-

Chỉ số	Tên tiếng Việt	Mô tả	Công thức
high	Giá cao nhất	Mức giá cao nhất trong phiên giao dịch	-
low	Giá thấp nhất	Mức giá thấp nhất trong phiên giao dịch	-
volume	Khối lượng giao dịch	Tổng số cổ phiếu/hợp đồng được giao dịch trong phiên	-
{t}_return	Tỷ suất lợi nhuận theo thời gian	Tỷ lệ thay đổi giá theo thời gian	$(\text{Giá}(t)/\text{Giá}(t - n)) - 1$
{t}_volatility	Độ biến động theo thời gian	Đo lường mức dao động giá trong khoảng thời gian	Độ lệch chuẩn của chuỗi lợi nhuận
{t}_liquidity	Tính thanh khoản theo thời gian	Đo mức độ dễ giao dịch của tài sản	Trung bình khối lượng giao dịch
high_minus_close	Chênh lệch Cao - Đóng	Hiệu giữa giá cao nhất và giá đóng cửa	high - close
low_minus_open	Chênh lệch Thấp - Mở	Hiệu giữa giá thấp nhất và giá mở cửa	low - open
cumulative_return	Lợi nhuận tích lũy	Tổng lợi nhuận từ đầu đến thời điểm hiện tại	$(\text{Giá}(t)/\text{Giá}(0)) - 1$
wma_{n}	Trung bình động có trọng số	Trung bình có trọng số giúp nhấn mạnh các giá gần nhất	Trọng số giảm dần theo thời gian

Chỉ số	Tên tiếng Việt	Mô tả	Công thức
obv	Khối lượng cân bằng (OBV)	Đo áp lực mua bán dựa trên khối lượng và hướng giá	$OBV(t) = OBV(t-1) \pm \text{volume}$
rsi_{n}	Chỉ số RSI	Đo tốc độ và mức thay đổi giá nhằm xác định quá mua/bán	$100 \times \frac{\text{Avg Gain}}{\text{Avg Gain} + \text{Avg Loss}}$
stoch_rsi_{n}	Stochastic RSI	RSI được chuẩn hóa trong khoảng [0, 1]	$(RSI - \min RSI) / (\max RSI - \min RSI)$
sma_{n}	Trung bình động đơn giản	Trung bình giá đóng cửa trong n ngày	Trung bình cộng của n phiên
ema_{n}	Trung bình động hàm mũ	Nhấn mạnh giá gần nhất, phản ứng nhanh với biến động	$EMA(t) = \alpha \cdot \text{Price}(t) + (1 - \alpha) \cdot EMA(t - 1)$
atr_{n}	Biên độ thực trung bình (ATR)	Đo mức biến động tổng thể của thị trường	$ATR = (1 - \alpha) \cdot ATR_{t-1} + \alpha \cdot TR_t$
mfi_{n}	Chỉ số dòng tiền (MFI)	Kết hợp giá và khối lượng để xác định dòng tiền mua bán	$MFI = 100 - \frac{100}{1 + \frac{PMF}{NMF}}$
adx_{n}	Chỉ số định hướng trung bình	Đo sức mạnh xu hướng dựa trên +DI và -DI	Trung bình ADX từ +DI và -DI
mom_{n}	Xung lượng (Momentum)	Đo tốc độ thay đổi của giá	$\text{Price}(t) - \text{Price}(t - n)$
cci_{n}	Chỉ số hàng hoá (CCI)	Nhận diện các dao động chu kỳ quanh giá trị trung bình	$CCI = \frac{TP - SMA(TP)}{0.015 \cdot MD}$

Chỉ số	Tên tiếng Việt	Mô tả	Công thức
rocr_{n}	Tỷ lệ thay đổi (ROCR)	So sánh giá hiện tại với giá trong quá khứ	$(\text{Price}(t) - \text{Price}(t-n)) \times 100$
out_macd	Đường MACD	Sự chênh lệch giữa EMA ngắn hạn và dài hạn	$\text{MACD} = \text{EMA}_{12} - \text{EMA}_{26}$
out_macd_signal	Đường tín hiệu MACD	EMA 9 ngày của MACD để tạo tín hiệu mua/bán	$\text{Signal} = \text{EMA}_9(\text{MACD})$
out_macd_hist	Histogram MACD	Độ lệch giữa MACD và đường tín hiệu	$\text{MACD} - \text{Signal}$
willr	Williams %R	Xác định trạng thái quá mua/quá bán so với vùng giá cao/thấp	$\frac{\text{High}_n - \text{Close}}{\text{High}_n - \text{Low}_n} \times 100$
tsf_{n}	Dự báo chuỗi thời gian (TSF)	Hồi quy tuyến tính để dự đoán xu hướng giá	Hồi quy tuyến tính n phiên
trix	TRIX	Đường dao động xác định thay đổi xu hướng	EMA bậc ba
bbandsmiddle	Dải giữa Bollinger	SMA20 làm đường trung tâm của dải Bollinger	SMA20
bbandsupper	Dải trên Bollinger	Ngưỡng trên thể hiện trạng thái quá mua	$\text{SMA}_{20} + 2 \times \text{độ lệch chuẩn}$
bbandslower	Dải dưới Bollinger	Ngưỡng dưới thể hiện trạng thái quá bán	$\text{SMA}_{20} - 2 \times \text{độ lệch chuẩn}$

Các chỉ báo kỹ thuật được chia thành các nhóm chức năng như sau:

1. Thay đổi giá – rocr_n, mom_n, cumulative_return, t_return
2. Phát hiện xu hướng – adx_n, mfi_n, tsf_n, trix
3. Tín hiệu mua bán – willr, rsi_n, cci_n, stoch_rsi_n, macd, macd_signal, macd_hist
4. Đo lường độ biến động – atr_n, t_volatility, bbandsupper, bbandslower
5. Đo lường khối lượng giao dịch – obv, t_liquidity, mfi_n
6. Làm mượt dữ liệu, khử nhiễu – sma_n, ema_n, wma_n, trix
7. Hỗ trợ tính toán – bbandsmiddle, high_minus_close, low_minus_open

Mỗi chỉ báo được tính theo các khoảng thời gian khác nhau từ 3 đến 100 ngày, và mỗi phiên bản theo từng khoảng đều được coi là một đặc trưng riêng biệt. Tổng cộng có **58 đặc trưng kỹ thuật** cho mỗi mã cổ phiếu, được định nghĩa như sau:

```
indicator_features = [
    'open', 'high', 'low', 'close', 'volume', '
    daily_return',
    'weekly_return', 'monthly_return', 'daily_volatility
    ', 'weekly_volatility',
    'monthly_volatility', 'daily_liquidity', '
    weekly_liquidity', 'monthly_liquidity',
    'high_minus_close', 'low_minus_open', '
    cumulative_return', 'wma_3', 'wma_7',
    'wma_14', 'wma_21', 'wma_50', 'wma_100', 'obv', '
    rsi_6', 'rsi_12', 'rsi_14',
    'stoch_rsi_6', 'stoch_rsi_12', 'stoch_rsi_14', '
    sma_3', 'sma_7', 'sma_14',
    'sma_21', 'sma_50', 'sma_100', 'ema_6', 'ema_12', '
    atr_14', 'mfi_14', 'adx_14',
    'adx_20', 'mom_1', 'mom_3', 'cci_12', 'cci_20', '
    rocr_3', 'rocr_12', 'out_macd',
    'out_macd_signal', 'out_macd_hist', 'willr', 'tsf_10
    ', 'tsf_20', 'trix',
    'bbandsmiddle', 'bbandsupper', 'bbandslower'
]
```

Listing 1: Danh sách các chỉ báo kỹ thuật

Ma trận đặc trưng X được biểu diễn như sau:

$$X(t) = \begin{bmatrix} \text{indicator_features}_{\text{mã_dự_đoán}}(t), \\ \text{indicator_features}_{\text{VN30}}(t), \\ \text{indicator_features}_{\text{VNINDEX}}(t) \end{bmatrix}$$

Trong đó, $X(t)$ là một vector hàng gồm các đặc trưng kỹ thuật của ba đối tượng: mã cổ phiếu cần dự đoán, chỉ số VN30 và chỉ số VNINDEX tại thời điểm t . Tổng số đặc trưng là:

$$3 \times \text{len}(\text{indicator_features}) = 3 \times 58 = 174$$

3.3 Chỉ số bên ngoài

Ngoài các chỉ báo kỹ thuật được tính từ chuỗi thời gian giá, chúng tôi bổ sung các **đặc trưng bên ngoài** đến từ: Báo cáo tài chính, dòng tiền, và tỷ số tài chính. Các đặc trưng này được cập nhật theo chu kỳ quý và được gắn vào khung dữ liệu theo ngày gần nhất tương ứng. Tất cả các giá trị được chuyển đổi đơn vị sang **ngàn đồng (kVND)** nhằm: Giảm hiện tượng bất ổn số học và Tăng tốc độ huấn luyện mô hình

Chỉ số	Tên tiếng Việt	Mô tả
year_revenue_growth	Tăng trưởng doanh thu năm	Mức tăng trưởng doanh thu so với cùng kỳ năm trước
quarter_revenue_growth	Tăng trưởng doanh thu quý	Tăng trưởng so với quý liền kề hoặc quý cùng kỳ
year_operation_profit_growth	Tăng trưởng lợi nhuận hoạt động năm	So sánh lợi nhuận hoạt động năm hiện tại và năm trước
quarter_operation_profit_growth	Tăng trưởng lợi nhuận hoạt động quý	So sánh theo quý gần nhất
year_share_holder_income_growth	Tăng trưởng thu nhập cổ đông năm	Biến động thu nhập thuộc về cổ đông theo năm
quarter_share_holder_income_growth	Tăng trưởng thu nhập cổ đông quý	Biến động thu nhập thuộc về cổ đông theo quý

Chỉ số	Tên tiếng Việt	Mô tả
price_to_earning	P/E	Định giá theo lợi nhuận (giá / thu nhập mỗi cổ phiếu)
price_to_book	P/B	Định giá theo giá trị sổ sách (giá / giá trị sổ sách)
roe	ROE	Lợi nhuận trên mỗi đồng vốn chủ sở hữu
roa	ROA	Khả năng tạo lợi nhuận từ tài sản
equity_on_total_asset	Vốn chủ / Tổng tài sản	Cấu trúc vốn doanh nghiệp
equity_on_liability	Vốn chủ / Nợ phải trả	Cân đối giữa vốn chủ sở hữu và nợ
eps_change	Biến động EPS	Tốc độ tăng trưởng EPS qua thời gian
asset_on_equity	Tài sản / Vốn chủ sở hữu	Hệ số đòn bẩy tài chính
payable_on_equity	Nợ phải trả / Vốn chủ sở hữu	Phản ánh áp lực tài chính của doanh nghiệp
book_value_per_share_change	Biến động giá trị sổ sách / CP	Biến động tài sản ròng chia theo cổ phần
invest_cost_kVND	Chi phí đầu tư	Chi phí doanh nghiệp bỏ ra cho đầu tư
from_invest_kVND	Lưu chuyển từ hoạt động đầu tư	Tiền thu vào từ đầu tư tài sản hoặc công ty khác
from_financial_kVND	Lưu chuyển từ tài chính	Lưu chuyển liên quan đến vay nợ, phát hành cổ phiếu
from_sale_kVND	Lưu chuyển từ bán hàng	Doanh thu tiền mặt từ hoạt động kinh doanh chính
free_cash_flow_kVND	Dòng tiền tự do	Tiền còn lại sau đầu tư để trả nợ hoặc chia cổ tức
revenue_kVND	Doanh thu thuần	Tổng doanh thu từ hoạt động bán hàng

Chỉ số	Tên tiếng Việt	Mô tả
operation_expense_kVND	Chi phí hoạt động	Tổng chi phí phát sinh trong kỳ kinh doanh
operation_profit_kVND	Lợi nhuận hoạt động	Lợi nhuận trước thuế và lãi vay
pre_tax_profit_kVND	Lợi nhuận trước thuế	Lợi nhuận trước khi trừ thuế thu nhập doanh nghiệp
post_tax_profit_kVND	Lợi nhuận sau thuế	Lợi nhuận ròng sau khi nộp thuế thu nhập doanh nghiệp
share_holder_income_kVND	Thu nhập cổ đông	Thu nhập cuối cùng thuộc về cổ đông công ty mẹ
earning_per_share_kVND	EPS (Lợi nhuận trên mỗi cổ phiếu)	Thu nhập trên một đơn vị cổ phần phổ thông
book_value_per_share_kVND	Giá trị sổ sách / cổ phiếu	Tổng tài sản ròng chia cho số cổ phần

Các đặc trưng bên ngoài được phân loại như sau:

- **Tăng trưởng theo thời gian:** `year_revenue_growth`, `eps_change`, ... giúp mô hình nắm được xu thế lợi nhuận hoặc rủi ro trong dài hạn.
- **Tỷ số tài chính:** `roe`, `roa`, `price_to_earning`, `price_to_book`, `equity_on_liability`, ... cung cấp thông tin về định giá và hiệu quả sử dụng vốn.
- **Dòng tiền và thu nhập:** `free_cash_flow_kVND`, `operation_profit_kVND`, `earning_per_share_kVND` phản ánh khả năng sinh lời thực tế của doanh nghiệp.

Tổng kết phần phân tích dữ liệu chúng ta có 20 files cho 20 mã cổ phiếu đã được thêm các đặc trưng từ chỉ số tài chính, thông tin của VN30, thông tin của VNINDEX, và nguồn thông tin bên ngoài. Tổng số đặc trưng là 201.


4 Tiền Xử Lí Dữ Liệu

4.1 Trực quan hóa dữ liệu

Sau khi hoàn thành quá trình xử lí dữ liệu, chúng tôi tiến hành trực quan hóa để phân tích xu hướng và sự phân bố của dữ liệu.


Trước tiên, từ biểu đồ có thể nhận thấy khối lượng giao dịch thường đạt đỉnh vào tháng 1 và có xu hướng gia tăng trở lại vào một số giai đoạn nhất định, đặc biệt là vào tháng 8 và tháng 12. Xu hướng này cho thấy sự tồn tại của yếu tố “mùa vụ” trong hoạt động giao dịch:

- **Giai đoạn đầu năm (tháng 1) và cuối năm (tháng 12):** Khối lượng giao dịch thường ở mức cao, có thể do dòng tiền mới được đưa vào thị trường, các kế hoạch đầu tư được triển khai, hoặc thị trường tái khởi động sau kỳ nghỉ dài. Vào cuối năm, hoạt động giao dịch gia tăng do nhu cầu tái cân bằng danh mục, chốt giá trị tài sản ròng (NAV) hoặc các hoạt động tài chính quan trọng khác.
- **Giai đoạn giữa năm (tháng 6, tháng 9):** Khối lượng giao dịch có xu hướng giảm, phản ánh sự chững lại của thị trường trong giai đoạn này.
- **Tháng 2 (dịp Tết Nguyên Đán tại Việt Nam):** Hoạt động giao dịch thường suy giảm đáng kể do kỳ nghỉ lễ kéo dài, ảnh hưởng đến thanh khoản thị trường.




Hình 4: Tổng khối lượng giao dịch theo tháng (2018-2025)

Về lợi nhuận trung bình của 20 mã trong khoảng 7 năm, khi trực quan theo tháng có thể thấy có 2 đỉnh (giữa năm và cuối năm - có thể liên quan tới hiệu ứng Santa Rally) và 3 đáy (tháng 3, 8, 10). Khi đó, các nhà đầu tư có thể cân nhắc tăng tỷ trọng ở những giai đoạn trước khi thị trường bước vào các tháng lợi nhuận cao, và thận trọng hơn vào các tháng có return âm.



Hình 5: Trung bình lợi nhuận của 20 mã theo tháng (2018-2025)

Ngoài ra, khi vẽ phân phối giá đóng cửa của các mã, chúng tôi nhận thấy rằng đa số cổ phiếu tập trung ở mức giá thấp (phổ biến trong khoảng 10.000 - 30.000 VND), trong khi chỉ có số ít cổ phiếu có giá cao, kéo "đuôi" phân phối về bên phải. Tuy nhiên, đây là hiện tượng thường gặp ở nhiều thị trường chứng khoán: số lượng lớn các cổ phiếu “mid-cap” hoặc “small-cap” và một nhóm nhỏ cổ phiếu “blue-chip” (hoặc vốn hóa lớn) được định giá cao.



Hình 6: Phân phối giá đóng cửa của 20 mã (2018-2025)



4.2 Lựa chọn đặc trưng

Với tổng cộng 201 đặc trưng kỹ thuật và tài chính, nguy cơ nhiễu và dư thừa thông tin là rất cao, dễ dẫn đến hiện tượng *overfitting* và làm giảm độ chính xác của mô hình. Do đó, chúng tôi tiến hành bước lựa chọn đặc trưng dựa trên sự kết hợp giữa phương pháp **tương quan tuyến tính (Pearson correlation)** và **mức ý nghĩa thống kê (p-value)** giữa đặc trưng và nhãn mục tiêu.

Cụ thể, các đặc trưng có p-value nhỏ hơn 0.05 và hệ số tương quan $|r| > 0.1$ so với biến mục tiêu `price_shift_target` được giữ lại, vì chúng thể hiện mối quan hệ đáng kể và ổn định về mặt thống kê. Ngoài ra, một tập hợp các đặc trưng quan trọng theo *domain knowledge* (ví dụ: `sma_7`, `rsi_14`, `macd_hist`, `obv`, `price_to_earning`, `price_to_book`, `adx_14`, ...) được ép buộc đưa vào mô hình nhằm đảm bảo tính nhất quán giữa các mã cổ phiếu. Những đặc trưng này cũng đóng vai trò lớn trong phần hậu xử lý dữ liệu (Post-processing) sau này. Tập đặc trưng cuối cùng là **giao** của các đặc trưng được chọn trên từng mã cổ phiếu, sau đó kết hợp thêm tập đặc trưng bắt buộc nói trên.

Sau khi chọn lọc tập đặc trưng cuối cùng, chúng tôi tiến hành kiểm tra những đặc trưng có mối tương quan cao nhất với biến mục tiêu, trong đó có 2 đặc trưng chúng tôi quan tâm là `close_kVND` và `cumulative_return`.

Trước tiên, chúng tôi trực quan hóa để lý giải độ tương quan giữa biến mục tiêu và đặc trưng `close_kVND`. Dựa theo biểu đồ phân tán ở dưới, có thể thấy dữ liệu phân bố dọc theo đường hồi quy dốc lên, xác nhận rằng các giai đoạn giá cao thường đi kèm mức chênh lệch 60 ngày cao (**độ tương quan dương mạnh**). Ngoài ra, từ sự phân bố và xu hướng trên 2 biểu đồ chúng tôi nhận thấy 1 đặc điểm chung của thị trường, trong đó cổ phiếu có giá cao thường có biên độ dao động lớn hơn. Bên cạnh đó, dải dữ liệu xung quanh đường chéo cho thấy mối quan hệ gần như tuyến tính, ít bị phân tán mạnh. Tuy nhiên, tương quan cao không nhất thiết khẳng định quan hệ nhân-quả (có thể cả 2 biến cùng bị chi phối bởi các yếu tố vĩ mô hoặc xu hướng thị trường chung).



Hình 7: Biểu đồ mô tả sự tương quan giữa đặc trưng `close_kVND` và biến mục tiêu

Tiếp theo, khi phân tích đặc trưng `cumulative_return`, có thể nhận thấy xu hướng chuyển động gần như tương đồng giữa 2 đường. Quan sát trên cho ta nhận xét rằng nếu lợi nhuận tích lũy (`cumulative_return`) đã tăng đáng kể, thì so với 60 ngày trước giá cũng thường cao hơn đáng kể - thể hiện 1 mô hình “**tích lũy – bùng nổ – điều chỉnh**” khá nhất quán. Kể đến, trong giai đoạn thị trường bùng nổ (2021-2022), `price_shift_60` tăng mạnh, vượt xa mức lãi/lỗ tích lũy. Khi thị trường điều chỉnh, `price_shift_60` lại giảm nhanh hơn. Những sự khác biệt này phản ánh rằng biến động ngắn hạn (`price_shift_60`) thường **nhảy** hơn và có **biến động lớn** hơn so với xu hướng dài hạn. Cuối cùng, quan sát biểu đồ chỉ ra rằng tương quan dương giữa `cumulative_return` và `price_shift_60` cho thấy khi một cổ phiếu (hoặc nhóm cổ phiếu) đã có xu hướng tăng tốt tính từ đầu giai đoạn, thì trong ngắn hạn (60 ngày) nó cũng thường duy trì được đà tăng mạnh. Ngược lại, khi thị trường bước vào chu kỳ giảm, `price_shift_60` thường lao dốc rõ rệt, kéo `cumulative_return` đi xuống sau đó. Chúng tôi nhận định rằng đây có thể được coi là một dạng **momentum effect**: xu hướng giá dài hạn (`cumulative_return`) và ngắn hạn (`price_shift_60`) cùng “đi chung một nhịp” trong giai đoạn tăng, nhưng ở chiều giảm, `price_shift_60` có thể biến động mạnh hơn, khiến `cumulative_return` “hao hụt” dần.



Hình 8: Biểu đồ đường mô tả sự tương quan giữa đặc trưng `cumulative_return` và biến mục tiêu

Ví dụ, với mục tiêu dự báo xu hướng giá cổ phiếu trong 60 ngày tương lai, một bộ gồm 91 đặc trưng đã được chọn. Trong đó, chúng tôi nhận thấy các đặc trưng mang tính dài hạn (như đường trung bình động `sma_50`, `sma_100`, `wma_50`, `wma_100`, và các chỉ số kỹ thuật liên quan đến Bollinger Bands, MACD, RSI) được giữ lại chủ yếu. Điều này phản ánh đúng tính chất của mục tiêu dự báo là xu hướng giá trong 60 ngày tới, cần nắm bắt xu hướng tổng thể

thay vì nhiều ngắn hạn. Các đặc trưng từ VN30 và VNINDEX cũng xuất hiện nhiều, nhấn mạnh vai trò của bối cảnh thị trường chung trong việc dự báo dài hạn. Ngoài ra, sự xuất hiện của các tỷ số tài chính như `price_to_book` hay `price_to_earning` là hợp lý vì chúng phản ánh giá trị thực và triển vọng tăng trưởng lâu dài của doanh nghiệp.

Việc lựa chọn ít đặc trưng ngắn hạn (3–7 ngày) giúp hạn chế rủi ro *overfitting*, phù hợp với mục tiêu dự đoán xu hướng trong thời gian dài.

5 Mô Hình Hóa

5.1 Giai đoạn 1

Trong giai đoạn đầu tiên của quá trình mô hình hóa, chúng tôi tiến hành tối ưu hóa cấu trúc và chuẩn bị dữ liệu đầu vào cho các mô hình dự đoán chuỗi thời gian. Quy trình này bao gồm ba bước chính: xử lý dữ liệu chuỗi thời gian, chuẩn hóa dữ liệu và xây dựng các bộ dữ liệu huấn luyện và kiểm thử.

Xử lý dữ liệu chuỗi thời gian: Chúng tôi áp dụng kỹ thuật tạo cửa sổ trượt (sliding window) với chiều dài **lookback = 120, 150 ngày** để xây dựng tập dữ liệu. Kỹ thuật này giúp mô hình học được mối quan hệ giữa các quan sát quá khứ và giá trị mục tiêu ở tương lai. Sẽ có hàm được xây dựng để chuyển đổi dữ liệu đặc trưng và nhãn thành các bộ dữ liệu đầu vào theo từng cửa sổ quan sát.

Chuẩn hóa dữ liệu: Chúng tôi áp dụng các kỹ thuật chuẩn hóa khác nhau cho đặc trưng và nhãn mục tiêu để tối ưu hiệu suất huấn luyện:

- Đối với nhãn mục tiêu, chúng tôi kết hợp hai phương án **MinMaxScaler** và **PowerTransformer** nhằm ổn định phương sai và đưa phân bố nhãn gần với phân phối chuẩn.
- Đối với các đặc trưng đầu vào, chúng tôi sử dụng **StandardScaler** để loại bỏ ảnh hưởng từ sự khác biệt về đơn vị và giá trị biên độ lớn.

Phân chia dữ liệu huấn luyện và kiểm thử: Dữ liệu được phân chia theo tỷ lệ **85%** huấn luyện và **15%** kiểm thử theo thứ tự thời gian, nhằm mô phỏng sát với điều kiện thực tế và tránh rò rỉ thông tin. Sau đó, tập dữ liệu huấn luyện của tất cả các mã cổ phiếu được kết hợp lại thành một tập hợp lớn để gia tăng sự đa dạng trong quá trình huấn luyện.

Xây dựng mô hình dự đoán: Trong bước này, chúng tôi đã triển khai và so sánh ba cấu trúc mạng neuron dự đoán chuỗi thời gian chính, bao gồm:

1. **LSTM (Long Short-Term Memory):** Mô hình gồm 3 tầng LSTM liên tiếp, giúp nắm bắt các mối quan hệ dài hạn trong chuỗi thời gian và giảm thiểu hiện tượng mất thông tin khi xử lý các chuỗi dữ liệu dài.

2. **GRU (Gated Recurrent Unit):** Mô hình gồm 2 tầng GRU liên tiếp, giúp giảm nhẹ độ phức tạp tính toán so với LSTM trong khi vẫn duy trì hiệu suất dự đoán ổn định.
3. **CNN-BiLSTM-Attention:** Đây là cấu trúc mô hình phức tạp hơn, kết hợp mạng CNN (Convolutional Neural Network) để trích xuất đặc trưng cục bộ, mạng BiLSTM (Bidirectional LSTM) để nắm bắt thông tin theo hai hướng thời gian, và cơ chế Attention để tập trung vào các đặc điểm quan trọng nhất trong dữ liệu đầu vào.

Các mô hình trên đều được huấn luyện bằng bộ dữ liệu đã được chuẩn bị kỹ lưỡng, sau đó đánh giá hiệu quả thông qua các độ đo hiệu suất như RMSE, MAPE, và R^2 . Việc triển khai song song ba kiến trúc khác nhau giúp chúng tôi đánh giá rõ ràng hơn các ưu điểm và hạn chế của từng mô hình, từ đó đưa ra lựa chọn tốt nhất cho nhiệm vụ dự đoán xu hướng giá dài hạn trong các khoảng 30, 60, 90 và 180 ngày.

Khung thời gian	Mô hình	RMSE	MAPE	R^2
30 ngày	LSTM	0.433	0.938	0.770
	GRU	0.744	1.072	-0.863
	CNN-BiLSTM-Attn	0.679	0.933	-0.555
60 ngày	LSTM	0.175	0.578	0.962
	GRU	0.216	0.306	0.844
	CNN-BiLSTM-Attn	0.294	0.244	0.713
90 ngày	LSTM	0.176	2.149	0.962
	GRU	0.193	0.347	0.877
	CNN-BiLSTM-Attn	0.356	0.401	0.585
180 ngày	LSTM	0.186	0.611	0.957
	GRU	0.179	1.402	0.897
	CNN-BiLSTM-Attn	0.568	1.731	-0.036

Bảng 3: Kết quả so sánh hiệu suất dự đoán của các mô hình theo các khung thời gian horizon khác nhau (lookback = 120).

Từ bảng 3, có thể thấy rằng mô hình LSTM thường đạt hiệu suất vượt trội với giá trị RMSE thấp và hệ số R^2 cao ở các khung thời gian ngắn (30 và 60 ngày), cho thấy khả năng dự báo ổn định và chính xác. Ở khung 90 ngày,

LSTM vẫn dẫn đầu, trong khi GRU thể hiện mức sai số RMSE và MAPE hợp lý nhưng kém hơn về độ giải thích phương sai. Đáng chú ý, tại khung 180 ngày, GRU có RMSE thấp nhất, gợi ý rằng mô hình này có khả năng tận dụng xu hướng dài hạn tốt hơn.

Khung thời gian	Mô hình	RMSE	MAPE	R ²
30 ngày	LSTM	0.554	1.389	0.624
	GRU	0.300	0.167	-4.988
	CNN-BiLSTM-Attn	0.108	0.062	0.254
60 ngày	LSTM	0.186	0.092	-1.316
	GRU	0.063	0.035	0.749
	CNN-BiLSTM-Attn	0.108	0.062	0.254
90 ngày	LSTM	0.141	2.366	0.976
	GRU	0.165	0.261	0.910
	CNN-BiLSTM-Attn	0.195	0.423	0.875
180 ngày	LSTM	0.169	0.675	0.965
	GRU	0.167	1.950	0.910
	CNN-BiLSTM-Attn	0.208	0.551	0.861

Bảng 4: Kết quả so sánh hiệu suất dự đoán của các mô hình theo các khung thời gian horizon khác nhau (lookback=150).

5.2 Hậu xử lý (post-processing)

Sau khi có kết quả dự đoán ban đầu từ các mô hình, chúng tôi thực hiện thêm bước hậu xử lý nhằm điều chỉnh giá dự đoán dựa trên các chỉ báo kỹ thuật và các quy tắc thị trường. Quy trình này được triển khai thông qua hàm đã được tạo, sử dụng các chỉ báo như đường trung bình động (MA), RSI, MACD, Bollinger Bands, Stochastic Oscillator, ADX, ATR, và các tỷ số tài chính như P/E, P/B để tinh chỉnh dự đoán.

Các quy tắc điều chỉnh giá được xây dựng dựa trên các trạng thái thị trường đặc trưng, bao gồm trạng thái quá mua (overbought), quá bán (oversold), xu hướng tăng giá (bullish), xu hướng giảm giá (bearish), trạng thái trung tính (neutral), cũng như các tín hiệu hỗn hợp (mixed signals). Ví dụ, nếu giá dự đoán vượt quá biên trên của Bollinger Bands và chỉ báo RSI cho thấy trạng thái quá mua, giá sẽ được điều chỉnh giảm nhẹ để phản ánh khả năng đảo chiều.

Lợi ích của hậu xử lý (Post-processing): Việc áp dụng bước hậu xử lý cho phép điều chỉnh các giá trị dự báo thô từ mô hình học sâu dựa trên các tín hiệu kỹ thuật thực tế như RSI, MACD, Bollinger Bands, khối lượng giao dịch, P/E, P/B, v.v. Cơ chế này giúp làm mượt sai số, hạn chế các dự đoán bất hợp lý và phản ánh tốt hơn trạng thái thị trường tại từng thời điểm.

Qua kết quả thực nghiệm trên tập dữ liệu báo **90 ngày**, có thể thấy hậu xử lý đóng vai trò quan trọng trong việc *cải thiện tính ổn định và mức độ tin cậy của dự báo*. Ví dụ, ở cổ phiếu FPT, chỉ số R^2 tăng từ **0.7462** (Predicted) lên **0.8487** (Adjusted), cho thấy mô hình phù hợp tốt hơn với dữ liệu thực tế sau khi điều chỉnh. Một số cổ phiếu khác như PDR, ITD, NVB cũng cho thấy MAPE và RMSE giảm đáng kể, cho thấy hậu xử lý giúp giảm độ lệch và cải thiện chất lượng dự báo tổng thể.

Bên cạnh đó, trong các trường hợp thị trường biến động mạnh hoặc có tín hiệu nhiễu, hậu xử lý còn giúp ngăn ngừa tình trạng *overfitting* bằng cách điều chỉnh theo hướng bảo thủ dựa trên chỉ báo phân kỳ, hỗ trợ - kháng cự và sức mạnh xu hướng. Do đó, hậu xử lý không chỉ cải thiện số liệu định lượng mà còn nâng cao tính khả thi khi triển khai mô hình vào thực tiễn đầu tư.

5.3 Giai đoạn 2

Hàm mục tiêu được định nghĩa như sau:

$$f(\mathbf{w}) = -\left(\mu^T \mathbf{w} - \lambda_1 \mathbf{w}^T \Sigma \mathbf{w} + \lambda_2 \|\mathbf{w}\|_1\right)$$

Trong đó:

- $\mathbf{w} \in \mathbb{R}^n$ là vector trọng số phân bổ cho n tài sản.
- $\mu \in \mathbb{R}^n$ là vector lợi nhuận trung bình kỳ vọng, được tính từ các dự báo lợi nhuận của các tài sản.
- $\Sigma \in \mathbb{R}^{n \times n}$ là ma trận hiệp phương sai của các lợi nhuận dự báo.
- λ_1 là tham số điều chỉnh mức độ phạt đối với phương sai của danh mục (rủi ro).
- λ_2 là tham số điều chỉnh mức độ phạt chuẩn L1, nhằm khuyến khích độ thưa (sparsity) của vector trọng số.

Ta sẽ giải thích từng thành phần của biểu thức trong ngoặc:

1. Thành phần $\mu^T \mathbf{w}$

$$\mu^T \mathbf{w} = \sum_{i=1}^n \mu_i w_i$$

- Đây là **lợi nhuận kỳ vọng** của danh mục đầu tư. Mỗi w_i là trọng số của tài sản i và μ_i là lợi nhuận kỳ vọng của tài sản đó.
- Mục tiêu là *tăng* lợi nhuận danh mục, do đó phần này có dấu dương trong biểu thức.

2. Thành phần $\lambda_1 \mathbf{w}^T \Sigma \mathbf{w}$

$$\mathbf{w}^T \Sigma \mathbf{w} = \sum_{i=1}^n \sum_{j=1}^n w_i \Sigma_{ij} w_j$$

- Đây là **phương sai** (hoặc rủi ro) của danh mục đầu tư, phản ánh mức độ biến động của lợi nhuận.
- λ_1 là hệ số điều chỉnh, giúp cân bằng giữa mục tiêu tối đa hóa lợi nhuận và tối thiểu hóa rủi ro.
- Phần này được trừ đi vì chúng ta muốn *giảm* rủi ro cho danh mục.

3. Thành phần $\lambda_2 \|\mathbf{w}\|_1$

$$\|\mathbf{w}\|_1 = \sum_{i=1}^n |w_i|$$

- Chuẩn L_1 được sử dụng để khuyến khích **sparsity** (tính thưa của vector trọng số). Điều này có nghĩa là một số w_i sẽ trở nên bằng 0, giúp đơn giản hóa danh mục và có thể giảm thiểu overfitting.
- λ_2 là tham số điều chỉnh mức độ phạt dựa trên chuẩn L_1 .
- Phần này được cộng vào biểu thức mục tiêu để thúc đẩy việc lựa chọn một tập con các tài sản có khả năng sinh lợi tốt hơn, đồng thời giúp duy trì tính tối ưu của danh mục.

Vì mục tiêu của bài toán là tối đa hóa biểu thức trên, hàm mục tiêu được định nghĩa với dấu âm để chuyển bài toán tối đa hóa thành bài toán tối thiểu hóa:

$$f(\mathbf{w}) = -\left(\mu^T \mathbf{w} - \lambda_1 \mathbf{w}^T \Sigma \mathbf{w} + \lambda_2 \|\mathbf{w}\|_1\right).$$

Do đó, khi tìm giá trị nhỏ nhất của $f(\mathbf{w})$, ta đồng thời tìm được danh mục có lợi nhuận kỳ vọng cao, rủi ro thấp và có tính thừa cần thiết.

Model	Horizon (ngày)	Sharpe hàng năm	Độ biến động hàng năm	Giá trị cuối
LSTM	30	-0.022	0.005	58.22
LSTM	60	0.126	0.002	219.68
LSTM	90	0.070	0.002	120.63
GRU	30	-0.016	0.006	70.59
GRU	60	0.100	0.002	201.80
GRU	90	0.089	0.001	109.48
CNN_BiLSTM	30	-0.029	0.005	49.45
CNN_BiLSTM	60	0.147	0.001	225.46
CNN_BiLSTM	90	0.107	0.001	112.18

Bảng 4: Các chỉ số hiệu suất của các mô hình dự báo theo các khoảng thời gian khác nhau (lookback = 150, $\lambda_1 = 0.5$ và $\lambda_2 = 2$).

Giả dụ ta có 100 đồng ban đầu. Đáng lưu ý, kết quả cho thấy chu kỳ 60 ngày mang lại hiệu suất tốt với Sharpe dương và giá trị cuối cao, trong khi chu kỳ 30 ngày cho lợi nhuận âm và biến động lớn do giao dịch quá thường xuyên. Ở chu kỳ 90 ngày, hiệu suất giảm so với 60 ngày, cho thấy tần suất cần điều chỉnh. Cả ba mô hình LSTM, GRU và CNN_BiLSTM đều cải thiện rõ ở chu kỳ 60. Để ra khuyến nghị đầu tư cụ thể, cả ba mô hình LSTM, GRU, và CNN_BiLSTM dự đoán nên đầu tư vào cổ phiếu FPT.

6 Kết luận

Trong quá trình nghiên cứu, chúng tôi đã triển khai và đánh giá một chuỗi các mô hình học sâu dự báo giá cổ phiếu, bao gồm LSTM, GRU và CNN-BiLSTM-Attention, trên các khoảng dự báo (horizon) 30, 60, 90 và 180 ngày. Kết quả dự báo từ những mô hình này đã được đưa vào giai đoạn tối ưu hóa danh mục đầu tư, nhằm xác định chiến lược phân bổ tài sản dựa trên lợi suất dự báo và kiểm chứng bằng dữ liệu thực tế. Cụ thể, quy trình tổng quan gồm các bước chính sau:

1. **Xử lý dữ liệu:** Dữ liệu lịch sử được làm sạch, tạo đặc trưng (feature engineering), chia nhỏ (train-test split) và chuẩn hóa. Các mô hình (LSTM, GRU, CNN-BiLSTM-Attn) được huấn luyện, sau đó dự báo giá cho từng cổ phiếu ở các mốc thời gian tương lai khác nhau (30, 60, 90, 180 ngày).
2. **Tính toán lợi suất và tối ưu hóa danh mục:** Từ dự báo giá, chúng tôi tính toán lợi suất logarit, sau đó ứng dụng kỹ thuật tối ưu hóa danh mục (mean-variance kết hợp regularization) để phân bổ trọng số đầu tư. Lợi suất thực tế cũng được đối chiếu nhằm đánh giá chất lượng quyết định đầu tư.
3. **So sánh mô hình và phân tích hiệu quả:**
 - *Đánh giá chất lượng dự báo* qua các chỉ số như RMSE, MAPE, R^2 .
 - *Đánh giá hiệu quả danh mục* qua lợi suất trung bình hàng năm, độ biến động, hệ số Sharpe, và thống kê mức sụt giảm tối đa (Maximum Drawdown).
 - Lập bảng tổng hợp (Model, Horizon, RMSE, MAPE, R^2 , Annual Return, Volatility, Sharpe Ratio, ...) để so sánh toàn diện giữa các mô hình và khoảng thời gian dự báo.

Kết quả thực nghiệm cho thấy việc kết hợp các mô hình dự báo chuỗi thời gian hiện đại (LSTM, GRU, CNN-BiLSTM-Attn) với quy trình tối ưu danh mục động sẽ giúp nâng cao hiệu quả đầu tư, hạn chế rủi ro, cũng như mở ra hướng nghiên cứu và phát triển các chiến lược đầu tư tự động trong tương lai. Trong phạm vi nghiên cứu này, mỗi mô hình có thể thể hiện ưu nhược điểm khác nhau ở từng khung thời gian dự báo, phản ánh sự phức tạp và đa dạng của dữ liệu thị trường chứng khoán. Qua đó, việc so sánh đa chiều (về hiệu suất dự báo và lợi nhuận danh mục) là thiết yếu để lựa chọn mô hình và chiến lược đầu tư phù hợp.